

CNN 기반 HRV 분석을 통한 인지 과제 수행 능력 예측에 관한 연구

류형록, 강우석, 김경호
단국대학교

Classification of Cognitive Task Performance using HRV Features: A Convolutional Neural Network Approach

Hyeong-Rok Ryu, Woo-seok Kang Kyung-Ho Kim
Dankook University

Abstract - 인지 부하(Cognitive Load)는 고도의 집중력이 요구되는 상황에서 판단 오류를 유발하는 핵심 요인이나, 기존의 주관적 측정 방식은 실시간성 부족과 편향의 문제를 가진다. 이를 해결하고자 본 연구는 비침습적 PPG 센서로부터 얻은 심박 변이도(HRV) 특징을 활용했다. 이를 딥러닝 모델과 결합하여 인지 과제(N-Back) 수행 능력을 객관적으로 예측하는 시스템의 가능성을 탐구했다. 실험 결과, 제안된 모델은 평균 AUC 0.85, F1-Score 0.82를 달성하며 인지 부하에 따른 개인의 과제 수행 능력을 성공적으로 분류할 수 있음을 확인했다. 이는 PPG 신호와 딥러닝을 결합한 비침습적 실시간 인지부하 모니터링 시스템 개발의 가능성을 시사한다.


1. 서 론

인지 부하(Cognitive Load)는 작업 효율과 안전성에 직결되는 핵심 개념으로, 과도할 경우 주의력 저하 및 의사결정 오류를 유발하여 다양한 산업 현장에서 사고 발생 확률을 증가시킨다[1]. 이러한 문제의식 속에서, 실시간 모니터링이 가능한 생리적 지표를 활용한 인지 부하 측정이 각광받고 있으며[2], 특히 심박 변이도(HRV)는 자율신경계 변화를 민감하게 반영하여 인지 부하 상태를 나타내는 대표 지표로 보고되었다[3]. 그러나 기존 연구들은 여전히 PPG 신호의 형태 변화나 노이즈 간섭으로 인한 특징 추출의 어려움, 피험자 간 변동성 등의 한계를 가진다[4].

본 연구는 인지 과제 (N-Back)의 정답률을 기준으로 '상위/하위' 그룹으로 라벨링한 PPG 기반 심박변이도(HRV) 특징을 입력받아, 상위/하위 그룹을 분류하는 CNN 모델을 제안하고 그 유효성을 검증한다.

2. 본 론

2.1 시스템 구성



〈그림 1〉 시스템 구성도

〈그림 1〉은 본 연구에서 제안하는 전체 시스템의 구성도이다. 시스템은 크게 데이터 수집 하드웨어, 데이터 전처리, 딥러닝 모델로 구성된다. 데이터 수집 단계에서는 컷볼에 부착된 PPG 센서로부터 아날로그 신호를 획득한다. 이 신호는 아날로그 필터링 및 증폭 회로를 거친 후, STM32 마이크로컨트롤러에서 디지털로 변환된다. 펌웨어에 구현된 실시간 피크 검출 알고리즘은 변환된 신호에서 심박 지점을 찾아내어 최종적으로 심박 간 간격(IBI, RR) 데이터를 산출한다. 산출된 심박 간 간격(IBI, RR) 데이터는 Python 기반 환경에서 전처리된다. 먼저 과제 정답률을 기준으로 데이터를 '상위/하위' 그룹으로 라벨링한 후, 심박변이도(HRV) 특징을 추출한다. 최종적으로, 추출된 특징 벡터는 CNN 모델의 입력으로 사용되어 지도학습 방식으로 인지

과제(N-Back) 수행 능력을 예측하도록 학습 및 평가된다


2.1.1 PPG 아날로그 회로

본 연구에서는 LED와 포토다이오드를 포함한 PPG 센서를 사용했다. PPG 신호 획득을 위한 아날로그 회로도이다. 포토다이오드의 미세 전류는 트랜스임피던스 증폭기에서 전압으로 변환된 후, 다단계 액티브 대역 통과 필터를 거치며 증폭되고 고주파 노이즈가 제거되어 ADC로 입력된다.

2.1.2 디지털 신호 필터링

ARM사에서 제공하는 CMSIS-DSP 라이브러리를 이용하여 4차 IIR 대역 통과 디지털 필터를 구현하였다. 이는 PPG 신호의 유효 주파수 대역인 0.5Hz에서 5Hz 사이의 신호만 통과시켜 기저선 변동 및 고주파 잡음을 억제하였다.

2.1.3 심박 변이도(HRV) 특징



〈그림 2〉 심박 간 간격(IBI, RR)와 심박 변이도(HRV) 특징

〈그림 2〉는 심박 간 간격(IBI, RR)와 심박 변이도(HRV)이다. 심박 변이도(HRV)는 심박 간 간격(IBI, RR)의 변화를 정량화한 지표로, 자율신경계의 활동 상태를 간접적으로 보여준다. 본 연구에서는 심박 변이도(HRV)를 시간 영역과 주파수 영역으로 나누어 분석하였다. 시간 영역에서는 심박 간 간격(IBI, RR) 데이터의 통계적 특성을 직접 계산했다. 전반적인 심박 수준은 모든 RR 간격의 산술 평균인 MeanRR(1)로 파악했으며, 총 변동성은 RR 간격의 표준편차인 SDNN(2)으로 산출했다. 또한, 부교감 신경 활성도를 민감하게 반영하는 RMSSD(3)을 연속된 RR 간격 차이의 제곱 평균 제곱근으로 계산했다. 각 수식에서 RR_i 는 i 번째 심박 간격(ms)을, N 은 전체 심박 수를 의미한다.

$$MeanRR = \frac{1}{N} \sum_{i=1}^N RR_i \quad (1)$$

$$SDNN = \sqrt{\frac{1}{N-1} \sum_{i=1}^N (RR_i - MeanRR)^2} \quad (2)$$

$$RMSSD = \sqrt{\frac{1}{N-1} \sum_{i=1}^{N-1} (RR_{i+1} - RR_i)^2} \quad (3)$$

주파수 영역에서는 심박 간 간격(IBI, RR) 시계열을 스펙트럼으로 변환하여 파워를 분석했다. 먼저 주파수 f 에 대한 파워 분포인 파워 스펙트럼 밀도 $P(f)$ 를 계산한 뒤, 저주파(LF, 0.04~0.15Hz) 대역의 파워(4)와 고주파(HF, 0.15~0.40Hz) 대역의 파워(5)를 각각 산출했다. 최종적으로 자율신경계 균형을 나타내는 LF/HF Ratio(6)를 두 파워의 비율로 계산했으며, 이 지표는 인지 부하에 따라 증가하는 경향을 보인다.

$$LF_{power} = \int_{0.04}^{0.15} P(f)df \quad (4)$$


$$HF_{power} = \int_{0.15}^{0.40} P(f)df \quad (5)$$

$$LF/HF \text{ ratio} = \frac{LF_{power}}{HF_{power}} \quad (6)$$

2.1.4 입력 데이터 구성

연속적인 심박 변이도(HRV) 특징 벡터를 딥러닝 모델에 입력하기 위해 슬라이딩 윈도우 기법을 사용했다. 60초 길이의 윈도우를 4초 간격으로 이동시키며 총 12개의 시간 스텝을 가진 2차원 시퀀스 데이터를 생성했다. 각 시퀀스는 특정 시간 동안의 심박 변이도(HRV) 동적 변화 패턴을 압축하여 담겨 되며, 모델이 시간적 맥락을 학습하는 데 사용된다.

2.1.5 모델 아키텍처




〈그림 3〉 CNN 모델 블록도

〈그림 3〉은 본 연구에서 제안한 CNN 구조로, 본 연구에서 사용한 모델은 CNN 기반으로 Transformer Encoder를 결합한 하이브리드 구조이다. 초기 CNN 블록은 두 개의 Conv2d 층으로 구성되어, 2차원 시퀀스 데이터로부터 지역적인 시공간 특징을 추출한다. 이후 추출된 특징 맵은 패치 단위로 나뉘어 Transformer Encoder에 입력된다. Transformer Encoder는 멀티-헤드 셀프 어텐션 메커니즘을 통해 시퀀스 전체의 장기적인 시간적 의존성과 맥락을 학습하는 역할을 수행한다.

2.1.6 모델 학습 및 평가


모델의 성능은 5 Fold 교차 검증과 홀드아웃 테스트를 순차적으로 수행하여 검증했다. 먼저, 모델의 일반화 성능을 안정적으로 평가하기 위해 5 Fold 교차 검증을 실시했다. 이후, 학습 과정에 사용되지 않은 데이터로 최종 성능을 보고하고자 전체 데이터셋을 훈련(80%) 및 테스트(20%) 세트로 분할하여 홀드아웃 테스트를 진행했다. 모델 학습에는 인지 과제(N-Back) 정답률 중앙값을 기준으로 '상위/하위' 라벨링된 데이터를 사용했으며, AdamW 옵티마이저(학습률 $3e-4$), 배치 사이즈 64, 드롭아웃 0.3을 공통 적용했다. 클래스 불균형 문제는 손실 함수에 가중치를 부여하여 완화했으며, 최종 성능은 AUC, 정확도, F1-Score로 정량 평가했다.

2.2 실험 결과




〈그림 4〉 상위/하위 그룹의 PPG 및 심박 변이도(HRV) 파형

〈그림 4〉은 인지 과제 수행 능력에 따른 하위 그룹(좌)과 상위 그룹(우)의 대표적인 생리 신호 패턴을 비교하여 보여준다. 각 그룹의 패턴은 (a) PPG 신호 파형, (b) 슬라이딩 윈도우 방식으로 계산된 시간 영역 심박변이도(HRV) 지표인 Mean RR (파랑색), SDNN(주황색), RMSSD(초록색), 그리고 (c) 주파수 영역 HRV 지표인 LF/HF 비율의 세 가지 그래프로 구성된다.



〈그림 5〉 CNN 데이터셋에 대한 혼동 행렬

〈그림 5〉는 Fold 5에서 모델의 분류 성능을 평가한 혼동 행렬이다. 총 140개(하위 그룹 80, 상위 그룹 60)의 검증 데이터에 대해, 모델은 약 99.3%의 높은 전체 정확도를 달성했다. 상위 그룹과 하위 그룹의 F1-score는 각각 0.992, 0.994로 측정되어 클래스에 편향되지 않은 균형 잡힌 성능을 입증했으며, 이는 제안된 모델의 안정성과 신뢰성을 뒷받침한다.



〈그림 6〉 CNN의 학습 및 검증 과정의 손실 그래프

〈그림 6〉은 Fold 5에서의 모델 학습 과정에 따른 손실 변화를 보여준다. X축은 에포크, Y축은 손실 값을 나타내며, 훈련 손실과 검증 손실이 표시된다. 학습 초기에 훈련 및 검증 손실 값이 모두 빠르게 감소하며 약 25 에포크 이내에 0.1 이하의 매우 낮은 값으로 안정적으로 수렴한다. 이는 새로운 데이터에 대해서도 일반화 성능을 안정적으로 확보했음을 보여준다.

3. 결 론

본 연구는 PPG 신호 기반 심박 변이도(HRV) 특징과 딥러닝 모델을 활용하여 인지 과제(N-Back)의 수행 능력을 분류하는 시스템의 가능성을 탐구했다. 제안된 모델은 5 Fold 교차검증 및 홀드아웃 테스트를 통해 평균 AUC 0.85, F1-Score 0.82의 성능으로 개인의 인지 부하 상태를 효과적으로 분류할 수 있음을 확인했다. 이는 비침습적 PPG 센서와 딥러닝 기술을 결합하여 운전자, 군인 등 고위험 직무 종사자의 인지 부하를 객관적으로 모니터링하고, 인지 부하로 인한 사고를 예방하는 데 기여할 수 있음을 보여준다. 추후 다양한 인지 과제 및 사용자의 학습 데이터로 모델의 일반화 성능을 강화하고, 임베디드 시스템 최적화 기대된다.

감사의 글

본 실적은 단국대학교 산업기술연구소 소속 학부생 연구원이 참여하여 이룩한 연구성과물로서 해당 연구소는 2025년도 단국대학교 대학혁신지원사업 학부생 연구트랙제 사업의 지원을 받았음.

[참 고 문 헌]

- [1] 윤호성, 정은성, 김정룡, "헬리콥터 조종사의 정신적 작업부하가 생리적 반응과 주관적 반응에 미치는 영향", 대한인간공학회지, 제31권, 제1호, pp. 119-125, 2012.
- [2] 김민아, 홍상기, 이강복, 김정균, "인지부하 감지를 위한 심박 변이도(HRV)와 PRV의 파라미터 중요도 분석", 전자공학회논문지, 제60권, 제5호, pp. 70-77, 2023.
- [3] Massaro, S., & Pecchia, L., "Heart rate variability (심박 변이도(HRV)) analysis: a methodology for organizational neuroscience", Organizational Research Methods, Vol. 22, No. 1, pp. 354-393, 2019.
- [4] Elgendy, M. (2012). On the analysis of photoplethysmography signals: From pulse oximetry to arterial stiffness. Computers in Cardiology, 39, 861 - 864.